

- Gamma Dor 型脉动变星渐近等周期间隔自动搜索方案
 - 1. 项目目标
 - 2. 天体物理背景
 - 3. 数据预处理
 - 3.1 频率到周期转换
 - 3.2 频率清洗
 - 4. 总体算法流程
 - 5. 候选 Delta_P 扫描
 - 5.1 period echelle 折叠
 - 5.2 phase 聚集评分
 - 5.3 网格设置
 - 6. RANSAC 整数阶序列拟合
 - 6.1 基础模型
 - 6.2 RANSAC 步骤
 - 6.3 漏阶处理
 - 7. P-Delta P 趋势细化
 - 7.1 构造相邻周期间隔
 - 7.2 线性模型
 - 7.3 二次模型作为可选项
 - 8. 序列评分与置信度
 - 9. 显著性评估
 - 9.1 周期随机打乱
 - 9.2 保持频率窗口的随机化
 - 9.3 注入恢复实验
 - 10. 多序列与模式混叠
 - 11. 建议的软件结构
 - 12. 第一版最小可用实现
 - 13. 验证标准
 - 13.1 合成数据
 - 13.2 真实样本
 - 14. 主要风险与应对
 - 15. 推荐开发顺序
 - 16. 第二阶段扩展
 - 17. 推荐结论

Gamma Dor 型脉动变星渐近等周期间隔自动搜索方案

1. 项目目标

本项目面向 Kepler 与 TESS 光变曲线频谱分析后的频率列表，自动识别 gamma Dor 型脉动变星中高阶 g 模的渐近等周期间隔现象。

输入是一颗星的频率峰列表，至少包含：

- 频率 f
- 振幅 A
- 信噪比 S/N
- 频率误差 σ_f ，如果可得
- 峰来源标记，例如 Kepler、TESS、sector、quarter，若可得

输出是一组候选 g 模周期间隔序列：

- 最佳平均周期间隔 ΔP
- ΔP 不确定度
- 匹配到的周期列表
- 对应的相对径向阶编号 n
- $P-\Delta P$ 图中的斜率
- 模式数量 N_{modes}
- 周期覆盖范围 coverage
- 显著性或假警报概率 FAP
- 综合置信度 confidence_score
- 诊断图： $P-\Delta P$ 图与 period echelle 图

核心问题可以抽象为：在含有噪声峰、组合频率、谐波、漏检峰和旋转效应的周期集合中，寻找满足近似关系的子序列：

$$P_n \approx P_0 + n * \Delta P$$

实际 gamma Dor 星中，受近核心旋转、化学梯度和模式俘获影响，相邻周期间隔并非严格常数，因此算法需要允许 ΔP 随周期缓慢变化。

2. 天体物理背景

高阶低频 g 模在渐近近似下具有近似等周期间隔：

$$P_{n,l} \approx P_{l0} / \sqrt{l(l+1)} * (n + \epsilon)$$

其中：

- $P_{n,l}$ 是径向阶为 n 、球谐度为 l 的模式周期。
- P_{l0} 与恒星内部浮力频率结构有关。
- $\Delta P_l = P_{l0} / \sqrt{l(l+1)}$ 是对应 l 的渐近周期间隔。

在非旋转或弱旋转情形下，同一 l, m 模式序列在 P - ΔP 图中接近水平线；在旋转情形下，尤其对 gamma Dor 型星，序列常表现为带斜率的近似直线。顺行、逆行和轴对称模式的斜率和形态不同。

本项目第一阶段不直接做完整星震正演建模，而是完成稳健的自动探测：判断一颗星是否存在可信的渐近 g 模周期间隔序列，并给出可用于后续建模的候选参数。

3. 数据预处理

3.1 频率到周期转换

频率单位统一为 μHz ，周期单位统一为 d ：

$$P = 1 / f$$
$$\sigma_P \approx \sigma_f / f^2$$

需要剔除：

- $f \leq 0$ 的频率。
- 明显超出 gamma Dor g 模范围的频率。
- 误差或 S/N 不满足最低要求的峰。

建议初始搜索范围：

```
0.3 d <= P <= 3.0 d
0.005 d <= Delta_P <= 0.08 d
```

实际范围应保留为配置项。Kepler 数据可用更低的噪声阈值，TESS 数据因时间跨度短、频率分辨率较差，默认阈值应更保守。

3.2 频率清洗

频率列表中常见污染包括：

- 谐波： $2f_i, 3f_i$
- 组合频率： $f_i + f_j, |f_i - f_j|$
- 旋转调制或活动相关低频峰
- 仪器系统峰
- TESS sector 拼接带来的窗口函数残留

建议实现两层清洗：

1. 轻量清洗：只剔除已知坏峰和低 S/N 峰。
2. 保守标记：不直接删除疑似组合频率，而是降低权重。

权重可定义为：

```
w_i = q_snr * q_amp * q_source * q_clean
```

其中：

- q_{snr} 随 S/N 增大而增大。
- q_{amp} 可使用振幅排序或归一化振幅。
- q_{source} 表示多数据源重复检出的可信度。
- q_{clean} 对疑似组合频率、谐波或仪器峰降权。

4. 总体算法流程

推荐采用三阶段流程：

频率清洗
-> 周期转换
-> Delta_P 网格扫描
-> phase 聚集评分
-> top-k 候选 Delta_P
-> RANSAC 整数阶序列拟合
-> P-Delta P 线性趋势细化
-> bootstrap / shuffle 显著性评估
-> 输出候选序列和诊断图

这个组合兼顾速度和鲁棒性：

- 网格扫描负责快速生成候选 **Delta_P**。
- phase 聚集评分负责发现 period echelle 图中的 ridge。
- RANSAC 负责在大量离群峰中找出可信子序列。
- 线性趋势细化负责适配 gamma Dor 星常见的旋转斜率。
- bootstrap 或随机打乱负责估计假阳性概率。

5. 候选 Delta_P 扫描

5.1 period echelle 折叠

对每一个候选 **Delta_P**，计算周期相位：

$$\text{phi_i} = (\text{P_i} / \text{Delta_P}) \bmod 1$$

若存在真实的等周期间隔序列，一组周期会在相位空间聚集，或在 period echelle 图中形成 ridge。

period echelle 图可使用：

$$\begin{aligned} \text{x_i} &= \text{P_i} \bmod \text{Delta_P} \\ \text{y_i} &= \text{P_i} \end{aligned}$$

其中 **x_i** 是折叠后的周期位置，**y_i** 是原始周期。严格等间隔序列表现为近似竖直 ridge；有旋转斜率时，ridge 会倾斜。

5.2 phase 聚集评分

最简单的聚集评分是 Rayleigh power:

$$R(\Delta_P) = |\sum_i w_i * \exp(2\pi i j \phi_i)| / \sum_i w_i$$

R 越接近 1, 说明相位越集中。但真实数据可能有倾斜 ridge, 单纯相位聚集会漏检。因此建议同时计算局部窗口内的聚集:

$$R_{\text{local}}(\Delta_P) = \max \text{ over period windows } R_{\text{window}}$$

也可以使用相位熵:

$$H = -\sum_k p_k * \log(p_k)$$
$$\text{score_entropy} = 1 - H / \log(K)$$

其中 **K** 是相位分箱数。

初始候选评分:

$$\begin{aligned} \text{score_scan} = & \\ & a1 * R_{\text{global}} \\ & + a2 * R_{\text{local}} \\ & + a3 * \text{entropy_score} \\ & + a4 * \text{weighted_peak_count} \end{aligned}$$

推荐保留 **top_k = 20-50** 个候选 **Delta_P**, 并合并彼此过近的候选峰。

5.3 网格设置

Delta_P 网格步长需要小于典型残差容忍度。可按周期覆盖范围估计:

$$\begin{aligned} \text{delta_grid} &\leq \text{tolerance} / N_{\text{order_span}} \\ N_{\text{order_span}} &\sim (P_{\text{max}} - P_{\text{min}}) / \Delta_P \end{aligned}$$

第一版可使用固定步长:

```
delta_grid = 1e-4 d
```

后续优化为两级扫描：

1. 粗扫： $1e-4$ d 到 $5e-4$ d
2. 细扫：围绕候选峰使用 $1e-5$ d 到 $5e-5$ d

6. RANSAC 整数阶序列拟合

6.1 基础模型

对每个候选 Δ_P ，拟合：

$$P_i = P_0 + n_i * \Delta_P + \epsilon_i$$

其中 n_i 是未知整数。由于绝对径向阶通常未知，可以只输出相对阶：

$$n_i = \text{round}((P_i - P_0) / \Delta_P)$$

6.2 RANSAC 步骤

1. 从周期集合中随机选取两个或三个点。
2. 根据点间距估计候选 Δ_P 或修正现有 Δ_P 。
3. 为所有周期分配最近整数阶 n_i 。
4. 计算残差：

$$r_i = P_i - (P_0 + n_i * \Delta_P)$$

5. 满足 $|r_i| < \text{tolerance}_i$ 的点作为 inliers。
6. 使用 inliers 重新加权最小二乘拟合 P_0 与 Δ_P 。
7. 记录最高分模型。

容忍度建议同时考虑观测误差和物理偏离：

```
tolerance_i = max(k_sigma * sigma_P_i, tolerance_floor)
```

第一版可设置：

```
tolerance_floor = 0.005 d 到 0.02 d
```

更合理的做法是让容忍度随 ΔP 缩放：

```
tolerance_floor = eta * Delta_P  
eta = 0.05 到 0.20
```

6.3 漏阶处理

真实观测中经常漏掉部分径向阶，因此不要求相邻周期都被检出。对相邻 inliers 的阶差：

```
gap_i = n_{i+1} - n_i
```

允许 $\text{gap}_i > 1$ ，但需要加入惩罚：

```
gap_penalty = \sum_i \max(0, \text{gap}_i - 1)
```

如果连续漏阶过多，例如 $\text{gap}_i > 5$ ，应降低序列可信度或分裂为两条序列。

7. P-Delta P 趋势细化

7.1 构造相邻周期间隔

对 RANSAC 找到的 inliers，按相对阶 n 排序。若两点阶差为 1，则直接计算：

```
\Delta P_i = P_{i+1} - P_i
```


$$P_{\text{mid}_i} = (P_{\{i+1\}} + P_i) / 2$$

若阶差为 $k > 1$ ，可使用平均间隔：

$$\Delta P_i = (P_{\{i+1\}} - P_i) / k$$

并对该点降低权重。

7.2 线性模型

拟合：

$$\Delta P(P) = \Delta P_0 + s * (P - P_{\text{ref}})$$

其中：

- ΔP_0 是参考周期附近的平均周期间隔。
- s 是 P - ΔP 图中的斜率。
- P_{ref} 可取匹配周期的加权均值。

若 $|s|$ 显著大于 0，说明序列存在系统性倾斜，可能与近核心旋转有关。

7.3 二次模型作为可选项

对于快速旋转或周期范围较宽的星，线性模型可能不足。第二阶段可引入：

$$\Delta P(P) = \Delta P_0 + s_1 * (P - P_{\text{ref}}) + s_2 * (P - P_{\text{ref}})^2$$

但自动检测阶段建议默认只使用线性模型，避免过拟合。

8. 序列评分与置信度

最终评分应综合统计显著性和天体物理合理性。

建议评分项：

```
N = 匹配模式数量
coverage = (max(P_inlier) - min(P_inlier)) / (P_search_max - P_search_min)
coherence = 1 - robust_std(residual / tolerance)
gap_score = exp(-lambda_gap * gap_penalty)
weight_score = mean(w_i of inliers)
slope_quality = 线性 P-Delta P 拟合优度
```

综合分数：

```
confidence_score =
    b1 * log(1 + N)
    + b2 * coverage
    + b3 * coherence
    + b4 * gap_score
    + b5 * weight_score
    + b6 * slope_quality
    - b7 * complexity_penalty
```

初始判定阈值可设为：

- **N_modes** ≥ 5 ：最低可疑候选。
- **N_modes** ≥ 8 ：较可信候选。
- **coverage** ≥ 0.3 ：覆盖范围较好。
- **FAP** ≤ 0.01 ：统计显著。

这些阈值需要通过人工标注样本和注入恢复实验校准。

9. 显著性评估

9.1 周期随机打乱

保持周期数量、权重和搜索范围不变，随机生成同数量的周期，重复完整搜索流程，得到最高虚假评分分布。

```
FAP = count(score_random >= score_real) / N_random
```

建议：

```
N_random = 200 到 1000
```

9.2 保持频率窗口的随机化

对 TESS 或 Kepler 的频谱窗口影响明显的样本，完全均匀随机可能低估假阳性。可采用：

- 在局部周期窗口内随机重排周期。
- 保持相邻周期差分布的 bootstrap。
- 对频率而非周期随机化，再转换到周期。

9.3 注入恢复实验

为了评估完整 pipeline 的召回率，向真实背景峰列表中注入人工 g 模序列：

```
P_n = P_0 + n * Delta_P + noise  
Delta_P(P) = Delta_P_0 + s * (P - P_ref)
```

改变：

- 模式数量
- 漏检比例
- 残差幅度
- 斜率
- S/N 分布
- 污染峰数量

输出召回率、误报率和参数恢复偏差。

10. 多序列与模式混叠

一颗 gamma Dor 星可能存在多条序列，例如不同 **l**, **m** 模式。自动流程应支持多序列搜索：

1. 找到最高置信度序列。

2. 将该序列 inliers 标记为已使用，但不立即删除。
3. 对剩余峰或降权后的峰重新搜索。
4. 若新序列与旧序列共享过多点，合并或保留更高分者。

序列间关系可用于辅助判断：

$$\Delta P_{l=2} \approx \Delta P_{l=1} / \sqrt{3}$$

但第一版不应强制该关系，因为旋转会改变观测形态。

11. 建议的软件结构

建议 Python 包结构：

```
rotdetect_alg/  
  data.py           # 输入输出数据结构  
  preprocess.py     # 频率清洗与周期转换  
  scan.py           # Delta_P 网格扫描  
  ransac.py         # 整数阶序列拟合  
  refine.py         # P-Delta P 趋势拟合  
  significance.py   # bootstrap / shuffle / injection tests  
  score.py          # 统一评分函数  
  plot.py           # 诊断图  
  pipeline.py       # 单颗星端到端流程  
  config.py         # 默认配置  
tests/  
  test_synthetic_recovery.py  
  test_false_positive.py  
  test_gap_handling.py  
docs/  
  asymptotic_gmode_period_spacing_search.md
```

核心数据结构：

```
@dataclass  
class FrequencyPeak:  
    frequency: float  
    amplitude: float | None = None  
    snr: float | None = None  
    frequency_error: float | None = None  
    source: str | None = None  
    quality_flag: str | None = None  
  
@dataclass
```

```
class PeriodSpacingSequence:
    delta_p: float
    delta_p_error: float | None
    p0: float
    periods: list[float]
    radial_orders: list[int]
    residuals: list[float]
    slope: float | None
    n_modes: int
    coverage: float
    fap: float | None
    confidence_score: float
```

12. 第一版最小可用实现

第一版建议只实现端到端可跑通的稳健版本：

1. 输入 CSV: `frequency, amplitude, snr, frequency_error`
2. 转周期并按周期排序。
3. 使用固定 `Delta_P` 网格做 phase 聚集扫描。
4. 保留 top 20 个候选。
5. 对每个候选运行 RANSAC。
6. 输出最高分序列。
7. 生成两张 PNG:
 - `period_spacing.png`
 - `period_echelle.png`
8. 使用 200 次随机周期重排估计 FAP。

默认配置：

```
period_min = 0.3 d
period_max = 3.0 d
delta_p_min = 0.005 d
delta_p_max = 0.08 d
delta_p_grid = 1e-4 d
min_modes = 5
good_modes = 8
tolerance_fraction = 0.10
top_k_candidates = 20
n_random_fap = 200
```

13. 验证标准

13.1 合成数据

必须通过以下合成测试：

- 无噪声等间隔序列：恢复 ΔP 误差小于一个网格步长。
- 带 20% 漏检：仍能恢复主序列。
- 带 50% 随机污染峰：误差和 FAP 仍合理。
- 带线性斜率：能识别非零 $P-\Delta P$ 斜率。
- 纯随机峰：不应输出高置信度序列。

13.2 真实样本

建议收集三类人工标注样本：

- 文献中已确认有清晰周期间隔序列的 gamma Dor 星。
- 有疑似但不清晰序列的边界样本。
- 无明显 g 模序列或污染严重的负样本。

评估指标：

```
precision = 自动候选中真实序列比例
recall = 已知真实序列被找回比例
delta_p_bias = Delta_P_auto - Delta_P_literature
mode_match_rate = 匹配周期与人工标注周期的重合率
```

14. 主要风险与应对

风险	表现	应对
组合频率污染	假 ridge 或虚假 ΔP	组合频率降权，不直接删除
TESS 时间跨度短	频率分辨率不足，周期误差大	使用更大容忍度和更严格 FAP
快速旋转	ridge 弯曲，线性模型不足	第一版标记低拟合质量，第二版加入二次模型
多模式混叠	多条序列交叉或共享峰	迭代搜索与共享点惩罚
过拟合随机峰	随机数据也出现短序列	使用 FAP、最小模式数和覆盖范围阈值

15. 推荐开发顺序

1. 写合成数据生成器。
2. 实现 period conversion 和基础清洗。
3. 实现 **Delta_P** phase 扫描。
4. 实现 RANSAC 序列拟合。
5. 实现评分函数。
6. 实现诊断图。
7. 加入随机化 FAP。
8. 用合成数据校准阈值。
9. 用少量真实星人工检查。
10. 批量运行 Kepler / TESS 样本。

16. 第二阶段扩展

第二阶段可以加入更物理的模型：

- 传统近似框架下的旋转 g 模 pattern 拟合。
- 同时估计近核心旋转频率。
- 区分 prograde、retrograde 和 zonal modes。
- 使用贝叶斯模型比较不同 **l**, **m** 序列。
- 使用图搜索或动态规划替代 RANSAC，以更好处理长缺口。
- 使用机器学习分类器对候选诊断图打分，但不应替代可解释的物理评分。

17. 推荐结论

本项目最稳妥的第一版算法是：

```
Delta_P phase scan + RANSAC integer-sequence fitting + linear P-Delta P  
refinement + randomization FAP
```

它既能利用渐近等周期间隔的核心物理特征，又能适应 gamma Dor 星真实数据中的漏检、污染峰和旋转斜率。该方案输出的参数和诊断图也适合作为后续星震建模、人工复核和论文样本筛选的基础。